



人工智能及其航空应用

机器学习应用系统设计



项目大作业：飞机模拟滑行

- **项目目标**

- 获取图像信息，采用人工智能算法分析图像数据，控制转向和速度，使平稳、快速到达终点。

- **基本要求**

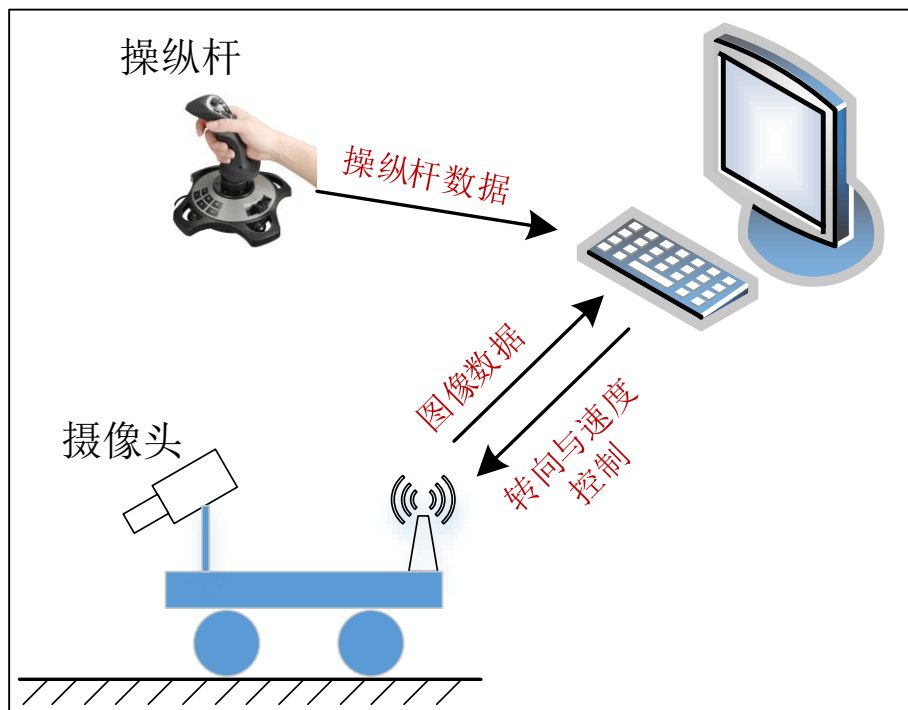
- 采用人工智能算法
- 利用Matlab等编程工具

- **考核方式**


- 根据是否能到达终点、运行速度等确定成绩



项目大作业：飞机模拟滑行



- 摄像头、操纵杆、树莓派、无线控制
- 基于视觉图像实现车辆方向控制



Matlab相关操作

- 获取图像步骤：
 - 创建ipcam对象
`cam = ipcam('http://192.168.0.1:8080')`
 - 从ipcam对象获取一幅图像
`img=snapshot(cam)`
 - 转换为灰度图像
`grayimg=rgb2gray(img)`
 - 缩放图像
`resizeimg=imresize(grayimg,[20,20])`

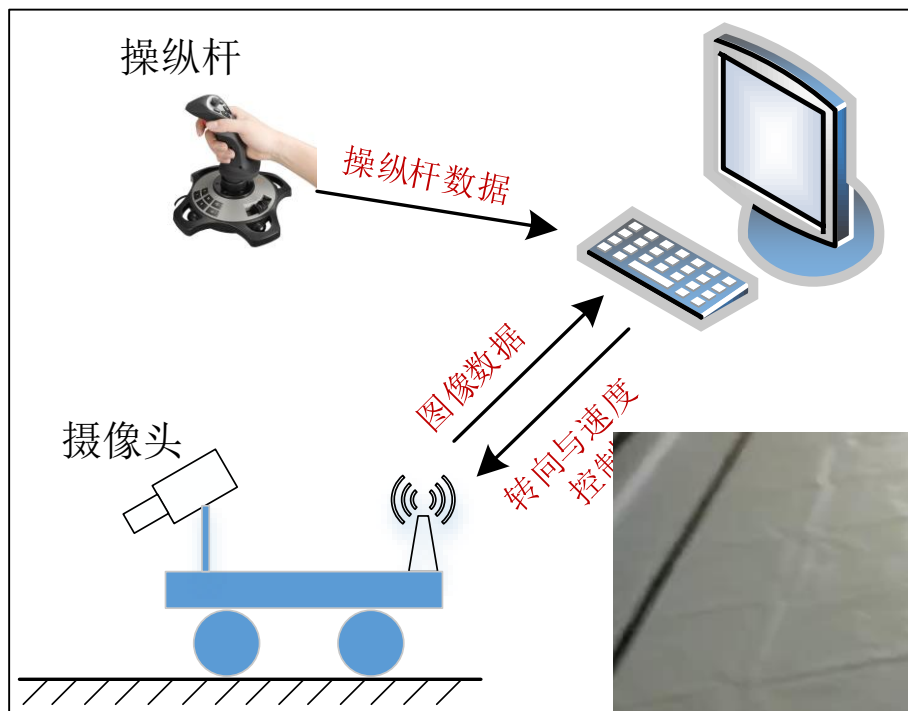
Matlab相关操作

- 获取操纵杆数据：
 - 创建操纵杆对象
`joy = vrjoystick(1) %相`
 - 获取操纵杆某一轴的值 %
`axis(joy,1)`
 - 获取操纵杆某一按键的值 %
`button(joy, 1)`


Matlab相关操作

- 发送小车控制指令：
 - 创建TCP/IP网络通信对象
`control_socket = tcpip('192.168.0.1',`
 - 将TCP/IP对象与小车控制器连接
`fopen(control_socket)`
 - 将指令发送给小车控制器
`fwrite(control_socket, 'S0,0,n,d,0,0,0`

项目大作业：飞机模拟滑行



- 摄像头、操纵杆、树莓派、无线控制
- 基于视觉图像实现车辆方向控制




项目大作业：飞机模拟滑行




航空科学与工程学院，人工智能及其航空应用

Monitor: OFF

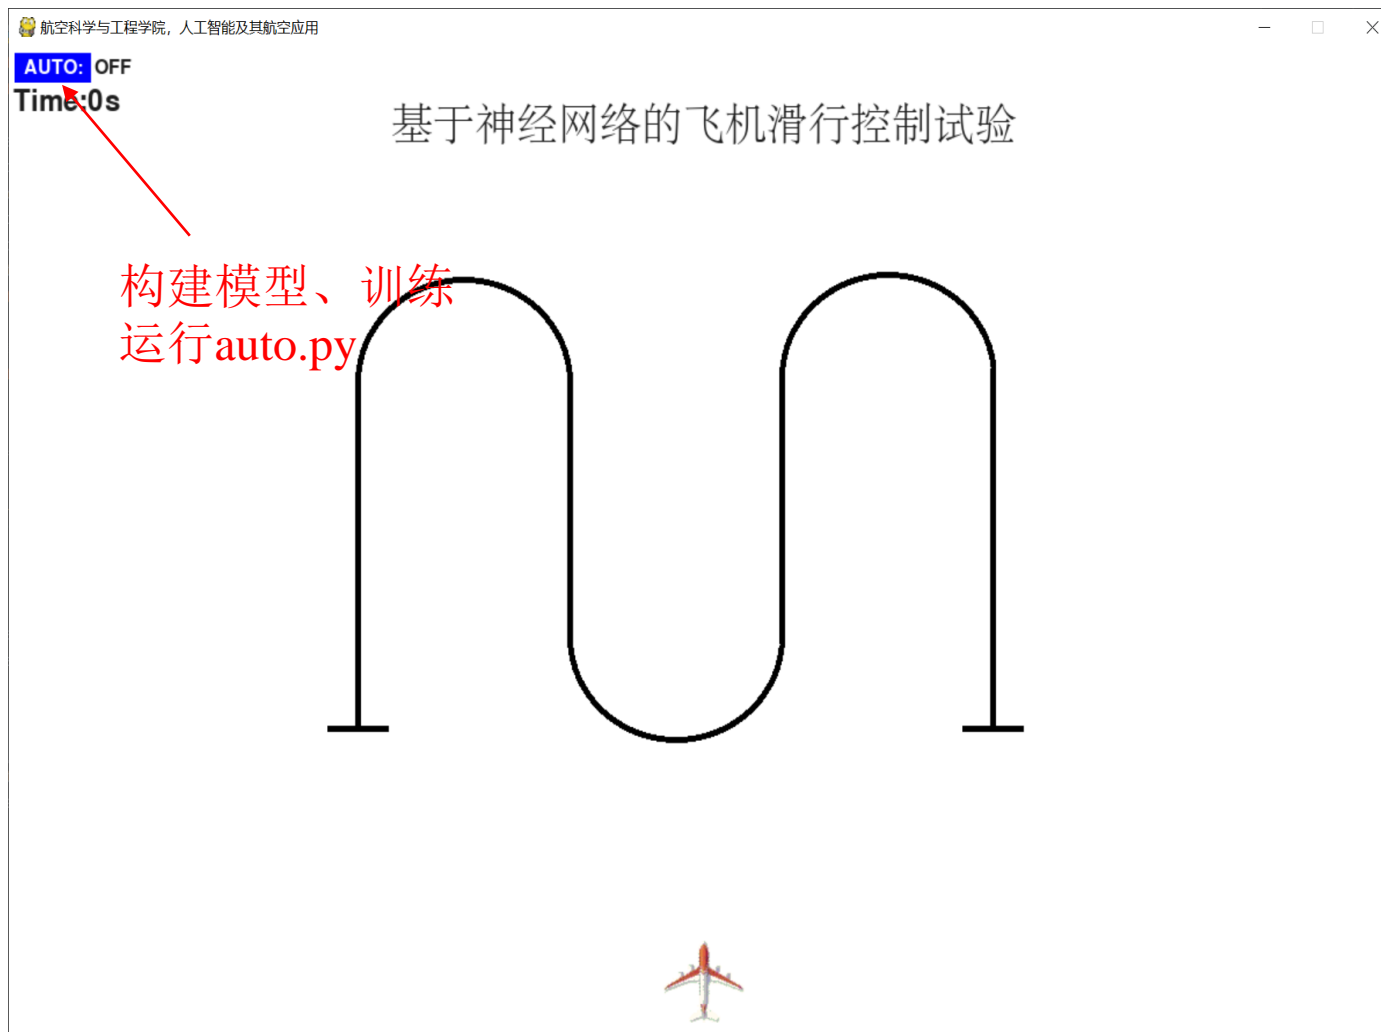
基于神经网络的飞机滑行控制试验



项目大作业：飞机模拟滑行



项目大作业：飞机模拟滑行




机器学习应用系统设计




如何设计机器学习系统？

如何提升机器学习系统的性能？

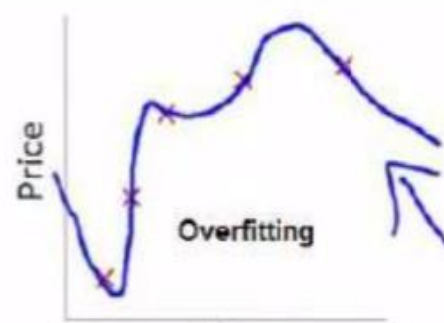
问题





$$\theta_0 + \theta_1 x$$



$$\theta_0 + \theta_1 x + \theta_2 x^2$$



$$\theta_0 + \theta_1 x + \theta_2 x^2 + \theta_3 x^3 + \theta_4 x^4$$





算法调试与优化方法

- 正则化线性回归方法——泛化预测...

$$h_{\theta}(x) = \theta_0 + \theta_1 x + \theta_2 x^2 + \theta_3 x^3 + \theta_4 x^4$$

$$J(\theta) = \frac{1}{2m} \left[\sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2 + \lambda \sum_{j=1}^m \theta_j^2 \right]$$

方法对新样本的预测偏差较大，
该如何改进算法的预测性能？

- 更多的训练样本
- 选用更少的特征集
- 获取更多特征的角度来收集更多的数据
- 增加多项式特征
- 减小或增大正则化参数

机器学习算法评估




➤ 算法诊断与评估

- 通过执行测试，深入了解学习算法是否有用，以及如何去提升算法的性能。

注意：

算法的诊断需要较长时间，但能指导算法调试的方法。

算法评估



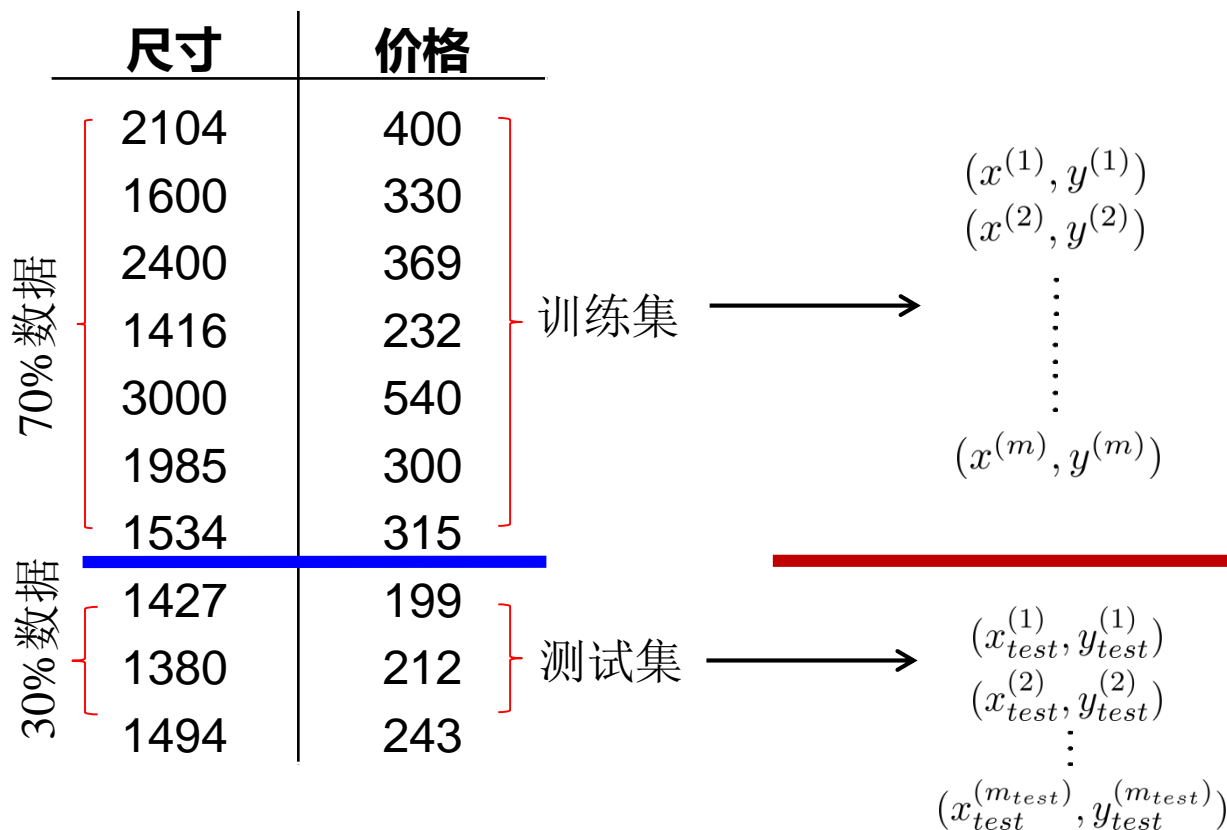
$$h_{\theta}(x) = \theta_0 + \theta_1 x + \theta_2 x^2 + \theta_3 x^3 + \theta_4 x^4$$

对新的数据集不适用

如何评估算法



数据集:



训练集和测试集必须要包含各种类型的数据



线性回归模型的训练与测试

- 利用训练集数据计算代价函数 J 得到参数 θ
 - 通过计算代价函数 $J(\theta)$ 的最小值。

$$J_{train}(\theta) = \frac{1}{2m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2$$

- 利用测试数据来计算误差

$$J_{test}(\theta) = \frac{1}{2m_{test}} \sum_{i=1}^{m_{test}} (h_{\theta}(x_{test}^{(i)}) - y_{test}^{(i)})^2$$



逻辑回归模型的训练与测试

- 利用训练集数据计算代价函数J得到参数 θ

$$J_{test}(\theta) = -\frac{1}{m_{test}} \sum_{i=1}^{m_{test}} y_{test}^{(i)} \log h_{\theta}(x_{test}^{(i)}) + (1 - y_{test}^{(i)}) \log h_{\theta}(x_{test}^{(i)})$$

- 利用测试数据来计算误差


误分类的比率，对于每一个测试集实例，计算：

$$err(h_{\theta}(x), y) = \begin{cases} 1 & \text{if } h(x) \geq 0.5 \text{ and } y = 0, \text{ or if } h(x) < 0.5 \text{ and } y = 1 \\ 0 & \text{Otherwise} \end{cases}$$

如何选择模型？



过拟合问题



$$h_{\theta}(x) = \theta_0 + \theta_1 x + \theta_2 x^2 + \theta_3 x^3 + \theta_4 x^4$$

训练集误差小并不说明
可很好的拟合新样本

模型选择



- ✓ 1. $h_{\theta}(x) = \theta_0 + \theta_1 x$
 - ✓ 2. $h_{\theta}(x) = \theta_0 + \theta_1 x + \theta_2 x^2$
 - ✓ 3. $h_{\theta}(x) = \theta_0 + \theta_1 x + \dots + \theta_3 x^3$
 - ⋮
 - ✓ 10. $h_{\theta}(x) = \theta_0 + \theta_1 x + \dots + \theta_{10} x^{10}$
- $J_{test}(\theta)$

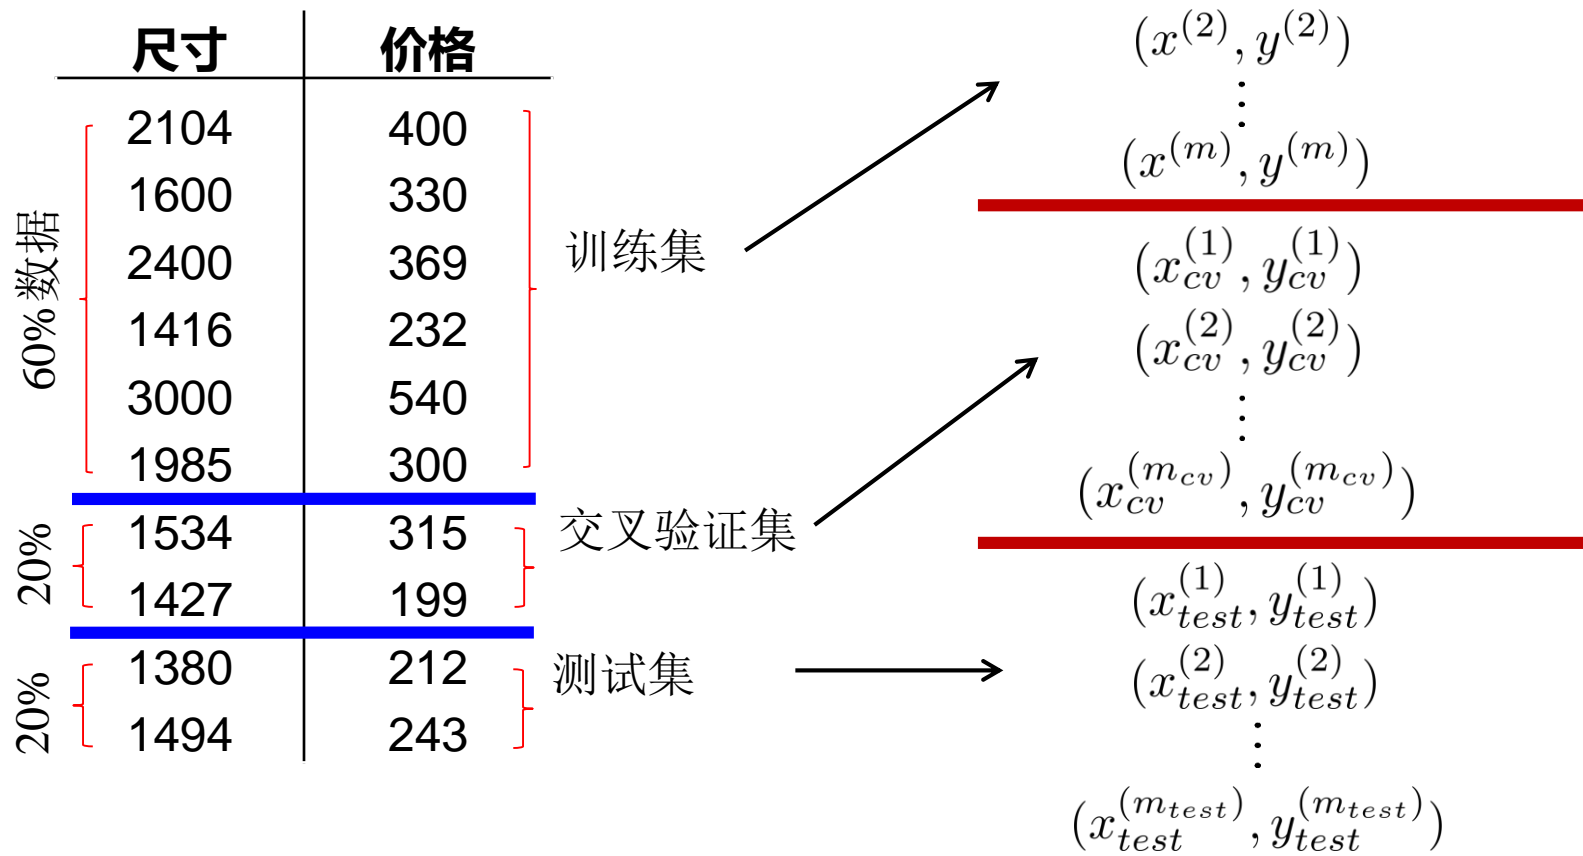
哪一个模型能适应一般的情况呢？

使用交叉验证集来帮助选择模型

模型评估



数据集:



模型评估



训练误差:

$$J_{train}(\theta) = \frac{1}{2m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2$$

交叉验证误差:

$$J_{cv}(\theta) = \frac{1}{2m_{cv}} \sum_{i=1}^{m_{cv}} (h_{\theta}(x_{cv}^{(i)}) - y_{cv}^{(i)})^2$$

测试集误差:

$$J_{test}(\theta) = \frac{1}{2m_{test}} \sum_{i=1}^{m_{test}} (h_{\theta}(x_{test}^{(i)}) - y_{test}^{(i)})^2$$

模型选择



$$\begin{array}{llll} 1. & h_{\theta}(x) = \theta_0 + \theta_1 x & \min J(\theta) \longrightarrow \theta^{(1)} & \longrightarrow J_{cv}(\theta^{(1)}) \\ 2. & h_{\theta}(x) = \theta_0 + \theta_1 x + \theta_2 x^2 & \longrightarrow \theta^{(2)} & \longrightarrow J_{cv}(\theta^{(2)}) \\ 3. & h_{\theta}(x) = \theta_0 + \theta_1 x + \cdots + \theta_3 x^3 & & \\ & \vdots & & \\ 10. & h_{\theta}(x) = \theta_0 + \theta_1 x + \cdots + \theta_{10} x^{10} & \longrightarrow \theta^{(10)} & \longrightarrow J_{cv}(\theta^{(10)}) \end{array}$$

- 根据 J_{cv} 值选择较小的模型
- 测试模型在测试集上的误差

模型偏差、方差评估




➤ 偏差

- 期望输出与真实标记的差别称为偏差, 度量了学习算法的期望预测与真实结果的偏离程度, 刻画了学习算法本身的拟合能力。


➤ 方差

- 方差度量了同样大小的训练集(样本数相同的不同训练集)的变动所导致的学习性能的变化, 即刻画了数据扰动所造成的影响。






偏差与方差




尺寸
 $\theta_0 + \theta_1 x$

高偏差(欠拟合)



尺寸
 $\theta_0 + \theta_1 x + \theta_2 x^2$

最佳



尺寸
 $\theta_0 + \theta_1 x + \theta_2 x^2 + \theta_3 x^3 + \theta_4 x^4$

高方差(过拟合)




一般来说，简单的模型会有一个较大的偏差和较小的方差，复杂的模型偏差较小方差较大



模型评估：偏差与方差

训练误差:
$$J_{train}(\theta) = \frac{1}{2m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2$$


交叉验证误差:
$$J_{cv}(\theta) = \frac{1}{2m_{cv}} \sum_{i=1}^{m_{cv}} (h_{\theta}(x_{cv}^{(i)}) - y_{cv}^{(i)})^2$$





模型评估：偏差与方差

- 对于训练集，当 d 较小时，模型误差较大，拟合程度低；随着 d 的增长，误差减小，拟合程度提高。
- 对于交叉验证集，当 d 较小时，模型误差较大，拟合程度低；但是随着 d 的增长，误差呈现先减小后增大的趋势，转折点是我们的模型开始过拟合时。







正则化线性回归

模型: $h_{\theta}(x) = \theta_0 + \theta_1 x + \theta_2 x^2 + \theta_3 x^3 + \theta_4 x^4$


$$J(\theta) = \frac{1}{2m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2 + \frac{\lambda}{2m} \sum_{j=1}^m \theta_j^2$$



尺寸
较大的 λ
高偏差(欠拟合)



尺寸
适中的 λ



尺寸
较小的 λ
高方差(过拟合)

$\lambda = 10000$. $\theta_1 \approx 0, \theta_2 \approx 0, \dots$
 $h_{\theta}(x) \approx \theta_0$

$\lambda = 0$



选择正则化参数

模型: $h_{\theta}(x) = \theta_0 + \theta_1 x + \theta_2 x^2 + \theta_3 x^3 + \theta_4 x^4$

$$J(\theta) = \frac{1}{2m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2 + \frac{\lambda}{2m} \sum_{j=1}^m \theta_j^2$$

1. 测试 $\lambda = 0$
2. 测试 $\lambda = 0.01$
3. 测试 $\lambda = 0.02$
4. 测试 $\lambda = 0.04$
5. 测试 $\lambda = 0.08$
- \vdots
12. 测试 $\lambda = 10$



选择正则化参数

$$h_{\theta}(x) = \theta_0 + \theta_1 x + \theta_2 x^2 + \theta_3 x^3 + \theta_4 x^4$$

$$J(\theta) = \frac{1}{2m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2 + \frac{\lambda}{2m} \sum_{j=1}^m \theta_j^2$$

$$J_{train}(\theta) = \frac{1}{2m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2$$

$$J_{cv}(\theta) = \frac{1}{2m_{cv}} \sum_{i=1}^{m_{cv}} (h_{\theta}(x_{cv}^{(i)}) - y_{cv}^{(i)})^2$$

$$J_{test}(\theta) = \frac{1}{2m_{test}} \sum_{i=1}^{m_{test}} (h_{\theta}(x_{test}^{(i)}) - y_{test}^{(i)})^2$$




选择正则化参数

$$J(\theta) = \frac{1}{2m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2 + \frac{\lambda}{2m} \sum_{j=1}^m \theta_j^2$$

$$J_{train}(\theta) = \frac{1}{2m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2$$

$$J_{cv}(\theta) = \frac{1}{2m_{cv}} \sum_{i=1}^{m_{cv}} (h_{\theta}(x_{cv}^{(i)}) - y_{cv}^{(i)})^2$$



- 当 λ 较小时，训练集误差较小(过拟合)而交叉验证集误差较大
- 随着 λ 的增加，训练集误差不断增加(欠拟合)，而交叉验证集误差则是先减小后增加





利用学习曲线判断偏差、方差问题


学习曲线:

$$J_{train}(\theta) = \frac{1}{2m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2$$

$$J_{cv}(\theta) = \frac{1}{2m_{cv}} \sum_{i=1}^{m_{cv}} (h_{\theta}(x_{cv}^{(i)}) - y_{cv}^{(i)})^2$$





高偏差



在高偏差/欠拟合的情况下，
增加数据到训练集对减小误差没有太大作用


$$h_{\theta}(x) = \theta_0 + \theta_1 x$$




高方差



$$h_{\theta}(x) = \theta_0 + \theta_1 x + \dots + \theta_{100} x^{100}$$



当交叉验证集误差远大于训练集误差时，往训练集增加更多数据可以提高模型的效果



小结



- 采用已由正则化线性回归方法预测


$$J(\theta) = \frac{1}{2m} \left[\sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2 + \lambda \sum_{j=1}^m \theta_j^2 \right]$$

对新样本的偏差较大，如何改进算法的预测性能？

- 更多的训练实例——解决高方差
- 减少特征数量——解决高方差
- 获得更多特征——解决高偏差
- 增加多项式特征——解决高偏差
- 减少正则化参数 λ ——解决高偏差
- 增加正则化参数 λ ——解决高方差


神经网络的方差和偏差

较小的神经网络
(结构简单、参数少; 倾向于欠拟合)



计算成本较低

较大的神经网络
(结构复杂、参数多; 倾向于过拟合)



计算成本较高
使用正则化参数解决过拟合问题.



机器学习应用系统设计-偏斜类误差度量

- 偏斜类情况
 - 训练集中有非常多的同一种类的实例，只有很少或没有其他类的实例

账号异常（盗用）的例子

- 训练逻辑回归模型 $h_{\theta}(x)$ ，为1表示异常，为0为正常。
- 只有0.1%的账号有异常

算法1: 神经网络训练

误差: 1%

算法2: 对任何情况均预测0

误差: 0.1%

对于偏斜类情况，需要有不同的误差度量方法



准确率/召回率（查全率）

- 设数据集中有较少 $Y=1$ 的样本，这些样本是需要检出的。

- 准确率**


- 准确率 P 是指判断为正确的样本中，实际为正确样本的比率：

$$P = TP / (TP + FP)$$

- 召回率**

- 召回率 R 是指所有正例样本中预测为正例样本的比例：

$$R = TP / (TP + FN)$$



True Positive (真正, TP)
True Negative (真负, TN)
False Positive (假正, FP)
False Negative (假负, FN)

被模型预测为正的正样本
被模型预测为负的负样本
被模型预测为正的负样本
被模型预测为负的正样本



准确率/召回率（查全率）

• 准确率/召回率的权衡

- 逻辑回归: $0 \leq h_{\theta}(x) \leq 1$
- 预测1: $h_{\theta}(x) \geq 0.5$
- 预测0: $h_{\theta}(x) < 0.5$

• 提高阈值

- 提高准确率P, 召回率R下降

• 减小阈值

- 提高召回率R, 准确率P下降

• 准确率


$$P = TP / (TP + FP)$$

• 召回率

$$R = TP / (TP + FN)$$

P和R指标矛盾, 需要综合考虑, 最常见的方法就是F1值 (F1-Score)


$$F1 = \frac{2 * P * R}{P + R}$$





机器学习应用系统设计-数据

- 数据集大时，不同类型的算法表现出了较好的效果。



- 如果一个模型具有很多参数（神经网络、拥有很多特征的线性回归、逻辑回归模型）——低偏差算法
 - 可以通过大量的数据集来降低方差。
 - 得到一个低方差和低偏差的学习算法